INFORME DE LABORATORIO

DYLAN RODRIGUEZ - DIEGO OCAMPO

Minería de Datos

Regresión Lineal Múltiple — Metodología CRISP-DM

Ejercicios incluidos:

Ejercicio 1: Predicción del Precio del Dólar
Ejercicio 2: Predicción de Niveles de Glucosa en Sangre
Ejercicio 3: Predicción del Consumo de Energía Eléctrica

REPOSITORIO:
https://github.com/DylanSantiagoRodriguez/entrenamiento_modelos_crisDM.git

Introducción General

El presente informe documenta el desarrollo completo de tres ejercicios de laboratorio en el área de Minería de Datos, todos aplicando Regresión Lineal Múltiple bajo la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining). Esta metodología proporciona un marco estructurado que cubre las fases de comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue.

Cada ejercicio aborda un dominio diferente: predicción financiera (precio del dólar), predicción clínica (glucosa en sangre) y predicción de consumo energético. A pesar de sus diferencias de dominio, los tres comparten el mismo pipeline metodológico, lo que permite comparar resultados y extraer conclusiones transversales sobre el uso de la regresión lineal en contextos variados.

EJERCICIO 1

Predicción del Precio del Dólar

1.1 Business Understanding (Comprensión del Negocio)

El objetivo principal de este ejercicio es construir un modelo de regresión lineal múltiple capaz de predecir el precio del dólar a partir de indicadores macroeconómicos diarios. La variable dependiente es Precio_Dolar, mientras que los predictores son: Dia (número de día en el período analizado), Inflacion (tasa de inflación diaria) y Tasa_interes (tasa de interés vigente).

La capacidad de anticipar movimientos cambiarios a partir de variables fácilmente observables tiene alta relevancia en contextos de planificación financiera, comercio exterior y política monetaria. El modelo permite, sin recurrir a instrumentos financieros sofisticados, obtener una estimación del comportamiento del tipo de cambio.

1.2 Data Understanding (Comprensión de los Datos)

El dataset utilizado corresponde al archivo dolar_data.csv. Contiene registros diarios con cuatro columnas numéricas: Dia, Inflacion, Tasa_interes y Precio_Dolar.

En la fase de exploración inicial se verificó la forma del dataset, las estadísticas descriptivas y la presencia de valores nulos. Adicionalmente, se calculó la matriz de correlación de Pearson entre todas las variables, representada visualmente mediante un heatmap. Esta herramienta permitió identificar cuáles predictores tienen mayor relación lineal con la variable objetivo, así como posibles relaciones de multicolinealidad entre los propios predictores.

Para facilitar la visualización comparativa de tendencias, se aplicó una normalización MinMaxScaler (rango 100–250) y se generó un gráfico de líneas múltiple que muestra la evolución simultánea del Precio del Dólar, la Inflación y la Tasa de Interés a lo largo del período. Esta visualización al estilo Economipedia permite apreciar relaciones visuales entre las series antes del modelado.

1.3 Data Preparation (Preparación de los Datos)

Se aplicó un pipeline de limpieza avanzada con los siguientes pasos secuenciales:

Paso	Técnica	Descripción
1	Estandarización de columnas	Eliminación de espacios en blanco en nombres de columnas
2	Valores nulos y duplicados	Eliminación de registros con NaN y registros duplicados
3	Conversión de tipos	Conversión a numérico con errors='coerce'; re-eliminación de NaN generados

Paso	Técnica	Descripción
4	Outliers por IQR (1.5×)	Eliminación de valores atípicos univariados por el método del rango intercuartílico
5	Redondeo	Estandarización a 4 decimales en columnas float

Tras la limpieza, el dataset se dividió en conjuntos de entrenamiento (80%) y prueba (20%) usando train_test_split con random_state=42, garantizando reproducibilidad. Las variables predictoras conformaron la matriz X = [Dia, Inflacion, Tasa_interes] y la variable objetivo el vector y = Precio_Dolar.

1.4 Modeling (Modelado)

Se entrenó un modelo de Regresión Lineal Múltiple utilizando sklearn.linear_model.LinearRegression sobre el conjunto de entrenamiento. La ecuación resultante del modelo adopta la forma:

$$\text{Precio_Dolar} = \beta_0 + \beta_1 \cdot \text{Dia} + \beta_2 \cdot \text{Inflacion} + \beta_3 \cdot \text{Tasa_interes}$$

La interpretación de los coeficientes es la siguiente:

Variable	Coeficiente	Interpretación
Dia	β_1	Por cada día adicional, el precio del dólar aumenta en β_1 unidades (tendencia temporal positiva)
Inflacion	β_2	Un aumento de 1 unidad en inflación modifica el precio en β_2 (generalmente positivo: más inflación → dólar más caro)
Tasa_interes	β_3	Por cada punto en tasa de interés, el precio varía en β_3 (puede ser negativo: tasas altas atraen capital y aprecian la moneda local)

El modelo fue exportado en formato .pkl usando joblib, con verificación posterior de carga y predicción de prueba para confirmar el correcto almacenamiento.

1.5 Evaluation (Evaluación)

Las métricas de desempeño calculadas sobre el conjunto de prueba fueron:

Métrica	Descripción	Interpretación
MSE	Error Cuadrático Medio	Penaliza errores grandes; menor valor indica mejor ajuste
RMSE	Raíz del MSE	Error en las mismas unidades que Precio_Dolar; facilita interpretación directa

Métrica	Descripción	Interpretación
R^2	Coeficiente de determinación	Proporción de varianza explicada por el modelo; 1.0 = ajuste perfecto

La gráfica de 'Real vs Predicho' compara los valores reales del conjunto de prueba contra las predicciones del modelo en un scatter plot con línea de referencia de predicción perfecta (diagonal roja). Adicionalmente, se generaron tres gráficas de dispersión individuales para cada predictor (Dia, Inflacion, Tasa_interes) contra Precio_Dolar, incluyendo líneas de tendencia mediante ajuste polinómico de grado 1.

1.6 Conclusiones del Ejercicio 1

- La regresión lineal múltiple con tres predictores macroeconómicos logra capturar la tendencia general del precio del dólar, aunque la precisión depende de la calidad y representatividad de las variables incluidas.
- El pipeline de limpieza con detección de outliers por IQR asegura que el modelo no sea influenciado por observaciones extremas que distorsionen los coeficientes.
- La interpretación de los coeficientes proporciona información económicamente válida: la tasa de interés puede mostrar coeficiente negativo (tasas altas atraen inversión extranjera, apreciando la moneda local), mientras que la inflación tiende a mostrar coeficiente positivo (mayor inflación → mayor precio del dólar).
- La exportación del modelo con joblib permite su reutilización en producción sin necesidad de reentrenamiento, validando la fase de despliegue de CRISP-DM.

EJERCICIO 2

Predicción de Niveles de Glucosa en Sangre

2.1 Business Understanding (Comprensión del Negocio)

El objetivo de este ejercicio es desarrollar un modelo predictivo del nivel de glucosa en sangre (mg/dL) a partir de variables clínicas básicas: Edad, IMC (Índice de Masa Corporal) y Actividad_Fisica (horas semanales). La predicción temprana del nivel de glucosa es clínicamente relevante ya que permite identificar pacientes en riesgo de diabetes tipo 2 sin recurrir a análisis de laboratorio costosos.

El objetivo de calidad establecido fue alcanzar un $R^2 \geq 0.70$ medido mediante validación cruzada de 10 pliegues (10-fold CV), garantizando estabilidad del resultado y que no sea dependiente de un único corte aleatorio de datos.

2.2 Data Understanding (Comprensión de los Datos)

El dataset glucosa_data.csv contiene 2,000 registros con 4 columnas:

Variable	Tipo	Rango	Descripción
Edad	Entero	20–79 años	Edad del paciente
IMC	Float	10.6–39.4	Índice de Masa Corporal
Actividad_Fisica	Entero	0–9 h/sem	Horas semanales de actividad física
Nivel_Glucosa	Float	43–227 mg/dL	Variable objetivo (nivel de glucosa)

El análisis de correlación de Pearson reveló la siguiente jerarquía de predictores:

- Edad: $r = 0.81$ — predictor dominante. Explica la mayor parte de la varianza en glucosa.
- Actividad_Fisica: $r = -0.19$ — relación negativa moderada (efecto protector del ejercicio).
- IMC: $r = 0.14$ — relación positiva débil (resistencia insulínica).

Esta estructura anticipa el techo teórico del modelo: con $r = 0.81$ para la variable principal, el R^2 máximo alcanzable con regresión lineal pura sobre Edad sería ≈ 0.66. Los demás predictores aportan incrementos marginales, y la inclusión de términos polinómicos e interacciones es necesaria para superar ese umbral.

2.3 Data Preparation (Preparación de los Datos)

Se diseñó un pipeline de limpieza en cuatro pasos encadenados:

#	Técnica	Filas eliminadas	Justificación
1	Estandarizar columnas y tipos	0	Elimina espacios; convierte a numérico con errors='coerce'

#	Técnica	Filas eliminadas	Justificación
2	Nulos y duplicados	0	Dataset sin nulos ni duplicados en la versión base
3	Outliers por IQR (1.5×)	~19	Elimina valores extremos univariados
4	Outliers por residuos (μ + 2.0σ)	~84	Detecta combinaciones anómalas no capturadas por IQR
Total		~103 (5.2%)	Filas finales: ~1,897 de 2,000

El Paso 4 es la innovación más importante: el método IQR evalúa cada columna de forma independiente y puede pasar por alto observaciones cuya combinación de valores es anómala aunque cada variable individual esté dentro de rango. Al entrenar un modelo preliminar y eliminar los residuos que superan μ + 2.0σ, se eliminan precisamente esas combinaciones incoherentes.

Ingeniería de Características

Se realizó búsqueda exhaustiva sobre todas las combinaciones posibles de variables derivadas, evaluando cada subconjunto con validación cruzada 10-fold. El subconjunto óptimo identificado fue:

Feature	Tipo	Justificación
Edad	Base	Correlación r=0.81 — predictor dominante
IMC	Base	Resistencia insulínica asociada al exceso de masa corporal
Actividad_Fisica	Base	Efecto protector del ejercicio sobre sensibilidad a la insulina
$Edad^2$	Derivado	Captura aceleración no lineal del metabolismo glucídico con la edad
$Edad^3$	Derivado	Modela aceleración mayor en edades avanzadas (>65 años)
IMC^2	Derivado	El efecto del IMC se acentúa en obesidad severa
Edad × IMC	Interacción	La obesidad tiene mayor impacto glucémico en personas mayores
Act^2	Derivado	Rendimiento decreciente del ejercicio: horas adicionales tienen efecto marginal menor

2.4 Modeling (Modelado)

Se experimentó con tres algoritmos distintos y cuatro tamaños de dataset para identificar el limitante real del problema:

Dataset	Lin. Regression	Random Forest	Grad. Boosting	Ridge + Feat. Eng.
500 filas	~67%	~63%	~64%	—
1,000 filas	~68%	~64%	~66%	—
2,000 filas	68.1%	63.2%	66.5%	~73% (CV)

Dataset	Lin. Regression	Random Forest	Grad. Boosting	Ridge + Feat. Eng.
5,000 filas	~68%	~65%	~67%	—

El análisis sistemático permitió establecer que el problema no era el volumen de datos ni el algoritmo, sino la capacidad informativa de los tres predictores disponibles. El R^2 se mantuvo estable en ~68% desde 500 hasta 5,000 registros para el modelo baseline.

Random Forest y Gradient Boosting no superaron al modelo lineal en validación cruzada, evidenciando sobreajuste. El modelo de Random Forest mostraba techo de entrenamiento muy superior al de prueba, confirmando que aprende ruido más que señal.

Modelo Final: Ridge Regression Optimizado

La solución que logró superar el umbral del 70% de forma estable fue Ridge Regression (regularización L2) combinada con el pipeline de limpieza reforzado y la ingeniería de características exhaustiva. Se eligió Ridge sobre LinearRegression por dos razones:

- La incorporación de $Edad^2$, $Edad^3$ y Edad×IMC introduce multicolinealidad entre predictores; Ridge estabiliza los coeficientes ante esta condición.
- La regularización L2 penaliza coeficientes excesivamente grandes, reduciendo el riesgo de sobreajuste al añadir más features.

El hiperparámetro alpha = 1 fue seleccionado mediante GridSearchCV con CV 10-fold sobre la grilla [0.001, 0.01, 0.05, 0.1, 0.5, 1, 5, 10, 50, 100].

2.5 Evaluation (Evaluación)

Métrica	Modelo Original	Modelo Optimizado
Modelo	LinearRegression	Ridge Regression (α=1)
Features	3 (base)	8 (3 base + 5 derivados)
Limpieza outliers	IQR (1 pasada)	IQR + residuos 2.0σ
Filas eliminadas	~19	~103 (5.2%)
Validación	Train/Test único	Train/Test + CV 10-fold
R^2 Test set	68.1%	~72–75%
R^2 CV promedio	—	73.0% ± 3.9% ✓
RMSE	~16 mg/dL	~13.7 mg/dL

La métrica de referencia es el R^2 de validación cruzada 10-fold (73.0% ± 3.9%), más confiable que el R^2 de un único split. El RMSE de ~13.7 mg/dL implica que el 68% de las predicciones caen dentro de ±14 mg/dL del valor real, rango clínicamente manejable para un cribado inicial.

El análisis de varianza residual sobre 100 splits aleatorios confirmó que el 28% de la varianza en Nivel_Glucosa es irreducible con los predictores disponibles (factores no medidos: genética, dieta, sueño, medicación, etc.). Para superar el 76% de forma estable se requieren variables adicionales.

Incorporación de Nuevas Variables (Extensión)

Como extensión del proyecto, se identificaron dos nuevas variables clínicas con potencial de reducir la varianza irreducible:

Variable	Unidad / Rango	Relevancia clínica
Insulina (2h post)	µU/mL (2–150)	Mide respuesta insulínica posprandial; valores elevados indican resistencia; correlación directa con glucosa
Presión Arterial	mmHg (60–180)	Hipertensión y hiperglucemia comparten mecanismos fisiopatológicos (resistencia insulínica, disfunción endotelial)

Se estima que con Insulina y Presión Arterial incluidas junto con el pipeline de features derivados ya desarrollado, el R^2 CV podría alcanzar el rango 76–82%.

2.6 Conclusiones del Ejercicio 2

- La metodología CRISP-DM permitió identificar tempranamente que el limitante no era el algoritmo ni el volumen de datos, sino la capacidad informativa de los tres predictores disponibles.
- El pipeline de limpieza en 4 pasos (IQR + residuos 2.0σ) demostró ser superior a la limpieza estándar, eliminando ~103 registros que el IQR solo no detectaba.
- Ridge Regression con 8 features (incluyendo términos polinómicos e interacciones) logró R^2 CV = 73.0% ± 3.9%, superando el objetivo del 70% de forma estable.
- El techo teórico del dataset con las variables originales es ~74%. Para llegar al 76% de forma consistente se requieren variables adicionales como Insulina y Presión Arterial.
- El modelo final (modelo_glucosa.pkl) es un Pipeline de scikit-learn que incluye escalado y regresión, listo para producción.

EJERCICIO 3

Predicción del Consumo de Energía Eléctrica

3.1 Business Understanding (Comprensión del Negocio)

El objetivo de este ejercicio es predecir el consumo de energía eléctrica (kWh) a partir de tres variables temporales y ambientales: Temperatura (°C), Hora del día (1–24) y Día de la semana (1=Lunes … 7=Domingo). El dataset utilizado es energia_data.csv y la variable objetivo es Consumo_Energia.

La predicción del consumo energético tiene aplicaciones directas en gestión de redes eléctricas, optimización de tarifas, planificación de capacidad y reducción de desperdicios energéticos. Un modelo preciso permite anticipar picos de demanda y ajustar la generación de forma eficiente.

3.2 Data Understanding y Data Preparation

El dataset contiene cuatro columnas numéricas: Temperatura (°C), Hora (valores 1 a 24), Dia_Semana (1 a 7) y Consumo_Energia (kWh). Se implementó una función de carga y validación automática que verifica la presencia de todas las columnas requeridas y la ausencia de valores faltantes (NaN), garantizando la integridad del dataset antes del modelado.

A diferencia de los ejercicios anteriores, la preparación de datos en este ejercicio se centra en la validación estructural del dataset, dado que las variables son inherentemente numéricas y el notebook está diseñado para fallar de forma informativa si el archivo no cumple los requisitos mínimos de calidad.

3.3 Modeling (Modelado)

Se entrenó un modelo de Regresión Lineal Múltiple (OLS — Ordinary Least Squares) usando sklearn.linear_model.LinearRegression. La división del dataset fue 80% entrenamiento / 20% prueba con random_state=42 y shuffle=True.

La ecuación del modelo adopta la forma:

$$\textbf{Consumo_Energia} = \beta_0 + \beta_1 \cdot \textbf{Temperatura} + \beta_2 \cdot \textbf{Hora} + \beta_3 \cdot \textbf{Dia_Semana}$$

Para comparar el impacto relativo de cada predictor de forma justa (dado que tienen distintas escalas y unidades), se calculó el impacto estandarizado mediante la fórmula:

$$Impacto_abs = |coeficiente| \times std(variable\ en\ train)$$

Este indicador permite identificar qué variable tiene el mayor efecto práctico sobre el consumo de energía en el contexto del dataset, independientemente de las unidades de medición. La variable con mayor impacto_abs_std es la que domina el modelo.

3.4 Evaluation (Evaluación)

Las métricas calculadas son RMSE (error en las mismas unidades que kWh, tanto en train como en test) y R^2 (proporción de varianza explicada). La comparación entre RMSE_train y RMSE_test

permite detectar posible sobreajuste: si RMSE_test >> RMSE_train, el modelo memoriza el entrenamiento sin generalizar bien.

El modelo fue evaluado reportando explícitamente la variable con mayor impacto según el indicador impacto_abs_std, lo cual es información accionable para la gestión energética (por ejemplo, si Temperatura domina, los sistemas de climatización son el principal driver del consumo).

Análisis de las Gráficas de Líneas (Real vs Predicho)

El notebook genera cuatro gráficas complementarias para la validación visual del modelo:

Gráfica	Eje X	Descripción e interpretación
1 — Por Temperatura	Temperatura (°C)	Datos ordenados por temperatura. Si las líneas se separan, el modelo no captura bien la relación no lineal con temperatura.
2 — Por Hora	Hora del día (1–24)	Muestra el perfil horario del consumo. Se esperan picos en horas laborales/nocturnas. El modelo debe reproducir estos patrones.
3 — Por Día de Semana	Día (Lun–Dom)	Revela diferencias entre días laborables y fin de semana. Un buen modelo debe capturar la caída de demanda en sábado y domingo.
4 — Semana completa	0–7 (días + fracciones horarias)	Visualización integrada: cada día ocupa ancho 1 y la hora recorre de izquierda a derecha dentro del día. Permite ver el patrón diario y semanal simultáneamente.

Es importante notar que en estas gráficas el eje X no representa el tiempo real de medición: los puntos se ordenan por la variable indicada. Esto permite ver el comportamiento marginal del consumo respecto a cada predictor, pero no implica relación causal: el modelo utiliza las tres variables simultáneamente en cada predicción.

3.5 Conclusiones del Ejercicio 3

- La regresión lineal múltiple sobre tres variables temporales y ambientales (Temperatura, Hora, Día de la semana) proporciona un modelo interpretable y directamente accionable para la gestión energética.
- El indicador de impacto estandarizado (|coeficiente| × std) permite comparar predictores de distintas escalas y determinar cuál variable domina el modelo en la práctica.
- Las cuatro gráficas de líneas proveen una validación visual multidimensional: permiten identificar patrones correctamente capturados y zonas donde el modelo lineal muestra limitaciones (por ejemplo, relaciones no lineales con la temperatura o perfiles horarios con múltiples picos).
- Si RMSE_test ≈ RMSE_train, el modelo generaliza adecuadamente. Si hay gap importante, se recomienda explorar ingeniería de características (variables cíclicas para Hora y Día, términos polinómicos para Temperatura).
- Una extensión natural del modelo sería codificar Hora y Día_Semana con funciones seno/coseno para capturar su naturaleza cíclica, lo que típicamente mejora el R^2 en modelos de series temporales con estacionalidad diaria y semanal.

Conclusiones Generales

Los tres ejercicios desarrollados en este laboratorio permiten extraer conclusiones transversales sobre el uso de la Regresión Lineal Múltiple en distintos dominios de aplicación.

Sobre la Metodología CRISP-DM

La aplicación sistemática de CRISP-DM en los tres ejercicios demostró su valor como marco estructurador del proceso de minería de datos. En particular, la fase de Business Understanding permitió establecer objetivos de calidad claros antes del modelado ($R^2 \geq 0.70$ en glucosa), evitando el problema común de construir modelos sin criterio de éxito definido. La fase de Evaluation, con validación cruzada 10-fold en el ejercicio de glucosa, garantizó que los resultados sean reproducibles y no dependientes de un único split aleatorio.

Sobre el Algoritmo de Regresión Lineal Múltiple

En los tres contextos analizados, la Regresión Lineal Múltiple demostró ser un algoritmo competitivo cuando se combina con un pipeline de preprocesamiento robusto e ingeniería de características adecuada. En el ejercicio de glucosa, superó a Random Forest y Gradient Boosting en validación cruzada, evidenciando que la complejidad del algoritmo no es la solución cuando el limitante es la capacidad informativa de los predictores.

Ejercicio	Variables	Modelo Final	Resultado
Dólar	Dia, Inflacion, Tasa_interes	LinearRegression + IQR	Predicción cambiaria con coeficientes económicamente interpretables
Glucosa	Edad, IMC, Actividad_Fisica + derivados	Ridge Regression (α=1)	R^2 CV = 73.0% ± 3.9% ✓ (objetivo: ≥ 70%)
Energía	Temperatura, Hora, Dia_Semana	LinearRegression + impacto_abs_std	Modelo con análisis de impacto relativo por predictor

Sobre el Preprocesamiento de Datos

El pipeline de limpieza demostró ser un factor determinante en la calidad del modelo, especialmente en el ejercicio de glucosa donde la detección de outliers multivariados por residuos ($\mu + 2.0\sigma$) mejoró el R^2 en varios puntos porcentuales respecto a la limpieza estándar por IQR. Este resultado enfatiza que la calidad de los datos importa más que la complejidad del algoritmo.

Recomendaciones para Trabajo Futuro

- Ejercicio 1 (Dólar): Incorporar variables macroeconómicas adicionales como reservas internacionales, balanza comercial y expectativas de mercado para mejorar la capacidad predictiva del modelo.
- Ejercicio 2 (Glucosa): Validar la mejora esperada con la incorporación de Insulina (2h post) y Presión Arterial. Para aplicaciones clínicas reales, complementar con HbA1c, historial familiar y datos de dieta.

- Ejercicio 3 (Energía): Explorar la codificación cíclica (seno/coseno) de Hora y Día_Semana, términos polinómicos para Temperatura, e incorporar variables meteorológicas adicionales (humedad, nubosidad) para capturar mejor la demanda de climatización.
- En todos los ejercicios: considerar modelos más expresivos (XGBoost, Redes Neuronales) solo cuando el análisis previo confirme que el limitante es realmente la capacidad del algoritmo y no la calidad o cantidad de los predictores disponibles.